

UNIVERSIDAD PÚBLICA DE EL ALTO
DIRECCIÓN DE POSGRADO
CENTRO DE ESTUDIOS Y FORMACIÓN DE POSGRADO E
INVESTIGACIÓN
“CEFORPI”



CLASIFICACIÓN DE LOS TIPOS DE APRENDIZAJE AUTOMÁTICO:
UNA REVISIÓN DOCUMENTAL DE SUS ENFOQUES PRINCIPALES

MONOGRAFÍA PRESENTADA EN
OPCIÓN AL DIPLOMADO EN
PROCESAMIENTO Y ANALISIS
MASIVO DE DATOS, 1ER. TÍTULO
INTERMEDIO DE LA MAESTRÍA EN
INTELIGENCIA ARTIFICIAL, MACHINE
LEARNING Y DATA SCIENCE,
VERSIÓN I, VIRTUAL.

AUTOR: RICHARD LORENZO SEVERICH PAREDES

EL ALTO – BOLIVIA

2025

Dedicatoria

Dedico este trabajo a todos los lectores que, más allá de buscar respuestas, se atreven a formular preguntas. A quienes comprenden que la investigación no es solo una actividad académica, sino un acto de responsabilidad con la verdad, el conocimiento y la sociedad.

Este esfuerzo está dirigido a ustedes, lectores inquietos, que entienden que cada dato, cada análisis y cada conclusión puede abrir caminos, transformar miradas y sembrar nuevas dudas que impulsen el progreso.

Richard Severich

Agradecimientos

Agradezco a todos los lectores de este trabajo, gracias por tomarse el tiempo de leer estas páginas, por permitir que mis ideas y reflexiones cobren sentido al ser compartidas. Es en ustedes donde este trabajo encuentra su propósito más profundo: inspirar, cuestionar o, al menos, acompañar en el camino del conocimiento.

Gracias por ser parte de este diálogo silencioso entre quien escribe y quien lee, entre quien busca y quien interpreta. Que este trabajo no sea un punto final, sino el inicio de nuevas reflexiones

Richard Severich

ÍNDICE

	Página
Dedicatoria.....	i
Agradecimiento.....	ii
Índice.....	iii
Resumen	viii
INTRODUCCIÓN.....	1
1 CAPÍTULO I.....	1
2 PRESENTACIÓN DE LA INVESTIGACIÓN	1
1.1 PLANTEAMIENTO DEL PROBLEMA	1
1.2 JUSTIFICACIÓN.....	2
1.3 METODOLOGÍA.....	2
1.3.1 Enfoque de investigación.....	2
1.3.2 Tipo de investigación	4
1.3.3 Diseño de investigación	4
1.3.4 Población y Muestra	5
1.3.4.1 Población.....	5
1.3.4.2 Muestra.....	5
1.3.4.3 Criterios de selección	5
1.3.4.4 Criterios de inclusión	6
1.3.4.5 Criterios de exclusión	6
1.3.5 Técnicas e instrumentos de recolección de información.....	6
1.4 OBJETIVOS DE LA INVESTIGACIÓN.....	7
1.4.1 Objetivo General	7
1.4.2 Objetivos Específicos.....	7
1.5 LÍMITES Y ALCANCES	7
1.5.1 Limites.....	7
1.5.2 Alcances.....	8
CAPÍTULO II	9
FUNDAMENTACIÓN TEÓRICA	9

2.1	Aprendizaje Supervisado.....	9
2.2	Características del Aprendizaje Supervisado.....	10
2.1.1	Ventajas del Aprendizaje Supervisado	10
2.1.2	Desventajas del Aprendizaje Supervisado	11
2.1.3	Aplicaciones del Aprendizaje Supervisado	12
2.2	Aprendizaje No Supervisado	12
2.2.1	Características del Aprendizaje No Supervisado	13
2.2.2	Ventajas del Aprendizaje No Supervisado	14
2.2.3	Desventajas del Aprendizaje No Supervisado	14
2.2.4	Aplicaciones del Aprendizaje No Supervisado	14
2.3	Aprendizaje por Refuerzo	15
2.3.1	Características del Aprendizaje por Refuerzo	16
2.3.2	Ventajas del Aprendizaje por Refuerzo	16
2.3.3	Desventajas del Aprendizaje por Refuerzo	17
2.3.4	Aplicaciones del Aprendizaje por Refuerzo	17
2.4	Aprendizaje semi-supervisado	18
2.4.1	Características del Aprendizaje semi-supervisado.....	18
2.4.2	Ventajas del Aprendizaje semi-supervisado.....	19
2.4.3	Desventajas del Aprendizaje semi-supervisado	19
2.4.4	Aplicaciones del Aprendizaje semi-supervisado	20
2.5	Aprendizaje auto-supervisado	20
2.5.1	Características del Aprendizaje auto-supervisado	21
2.5.2	Ventajas del Aprendizaje auto-supervisado	22
2.5.3	Desventajas del Aprendizaje auto-supervisado	22
2.5.4	Aplicaciones del Aprendizaje auto-supervisado	23
2.6	Tablas Comparativas	24
3	CAPÍTULO III	27
	CONCLUSIONES Y RECOMENDACIONES	27
	BIBLIOGRAFÍA.....	1
	CIBERGRAFÍA.....	2
	ANEXOS	3

INDICE DE FIGURAS

Figura 1: Proceso de búsqueda y extracción de la bibliografía.....	3
---	---

INDICE DE TABLAS

Tabla 1: Tabla Comparativa Definiciones	24
Tabla 2: Tabla Comparativa Aplicaciones.....	25
Tabla 3: Tabla Comparativa Algoritmos.....	26
Tabla 4: Referencias Extraídas Según Repositorio	4

RESUMEN

El Aprendizaje Automático, como rama fundamental de la Inteligencia Artificial, ha experimentado un crecimiento acelerado en los últimos años, diversificando sus enfoques y aplicaciones en múltiples áreas del conocimiento.

Sin embargo, esta expansión ha generado cierta dispersión conceptual que dificulta la comprensión y correcta selección de las técnicas más adecuadas para cada problema.

Esta monografía tiene como objetivo realizar una revisión y clasificación de los principales tipos de aprendizaje automático: supervisado, no supervisado, por refuerzo, semi-supervisado y auto-supervisado.

Para ello, se adoptó una metodología de investigación documental y bibliográfica, bajo un enfoque cualitativo y paradigma interpretativo-constructivista, analizando fuentes académicas y técnicas recientes.

Se describen las características, ventajas, desventajas y aplicaciones de cada enfoque, proporcionando un marco de referencia claro y actualizado que facilite su comprensión y uso en contextos académicos y profesionales.

Los resultados de la revisión evidencian que cada tipo de aprendizaje automático presenta fortalezas y limitaciones específicas, y que su selección debe basarse en criterios técnicos y contextuales más que en tendencias.

Este trabajo contribuye a la sistematización del conocimiento en el área, sirviendo como herramienta de apoyo para estudiantes, investigadores y profesionales interesados en el desarrollo y aplicación de soluciones basadas en aprendizaje automático.

Palabras clave: Aprendizaje Automático, Aprendizaje Supervisado, Aprendizaje No Supervisado, Aprendizaje por Refuerzo, Aprendizaje Semi-supervisado, Aprendizaje Auto-supervisado.

INTRODUCCIÓN

En las últimas décadas, el Aprendizaje Automático (Machine Learning) se ha consolidado como una de las áreas más influyentes y dinámicas dentro de la Inteligencia Artificial, impulsando avances significativos en sectores tan diversos como la medicina, la ingeniería, la economía, el transporte y la educación.

Sin embargo, su creciente relevancia viene acompañada de una amplia diversidad de enfoques, algoritmos y metodologías, lo que a menudo genera confusión en cuanto a su clasificación, características y aplicaciones.

Esta diversidad, si bien refleja la riqueza del campo, también dificulta la selección del enfoque más adecuado para resolver un problema específico, especialmente cuando las decisiones se basan más en tendencias tecnológicas que en un análisis riguroso y fundamentado.

En este contexto, comprender los distintos tipos de aprendizaje automático-supervisado, no supervisado, por refuerzo, semi-supervisado y auto-supervisado resulta esencial para estudiantes, investigadores y profesionales que buscan aplicar estas técnicas de manera estratégica y eficiente.

Cada uno de estos enfoques presenta fundamentos teóricos, ventajas, limitaciones y áreas de aplicación propias, cuya adecuada interpretación permite no solo optimizar resultados, sino también evitar implementaciones ineficientes o descontextualizadas.

La presente monografía tiene como propósito realizar una revisión y clasificación detallada de los principales tipos de Aprendizaje Automático, estableciendo un marco de referencia clara y actualizada que facilite su comprensión y uso correcto en contextos académicos y profesionales.

A través de un análisis documental y bibliográfico, se sistematiza la información existente para ofrecer una herramienta que oriente la selección de técnicas en función de criterios objetivos, contribuyendo así al fortalecimiento del conocimiento.

CAPÍTULO I

PRESENTACIÓN DE LA INVESTIGACIÓN

1.1 PLANTEAMIENTO DEL PROBLEMA

El Aprendizaje Automático (Machine Learning) ha llegado a ser uno de los soportes más relevantes de la Inteligencia Artificial, pero a pesar de esta importancia, todavía vive su devenir definitivo, lo que continúa produciendo confusión sobre los principales enfoques en los que se puede clasificar, por un lado, llanamente dificultando el aprendizaje en cuanto a los principios y aplicaciones y, por otro, la discusión de términos como aprendizaje supervisado, no supervisado y por refuerzo, como evidencia de aprendizaje de una manera con escaso análisis comparativo entre los distintos enfoques, sus ventajas y limitaciones y sus contextos más adecuados.

La profusión de investigaciones, algoritmos e incluso variantes, por ejemplo, el aprendizaje semi-supervisado o el auto-supervisado, ha generado un ecosistema mucho más complejo que, en contrapartida, escasa sistematización produce, en la comunidad de estudiantes, investigadores y profesionales una de las dificultades para poder seleccionar el tipo de aprendizaje que es más adecuado para resolver un problema. Esta situación se ve agravada por la existencia de la tendencia a incorporar tecnologías en función de la moda o popularidad sin que en ningún momento se aporte un fuerte soporte teórico a las decisiones técnicas y metodológicas.

Por lo tanto, es necesario realizar un estudio de revisión y clasificación en los tipos de Aprendizaje Automático, lo que permita tener un marco de referencia, no sólo más claro, sino más actualizado. Un trabajo de revisión de estas características podría facilitar la identificación de criterios objetivos para la selección de enfoques para utilizarlos teniendo, por tanto, un uso más objetivo y fundamentado de las tecnologías de Aprendizaje Automático en investigación académica y en el desarrollo de soluciones de aprendizaje en entornos de producción.

1.2 JUSTIFICACIÓN

El aumento del impacto del Aprendizaje Automático en los diferentes campos del conocimiento y el crecimiento del número de algoritmos y de estrategias han originado no solamente un aumento importante del número de algoritmos y de estrategias, sino también una cierta dispersión conceptual que hace difícil el entendimiento de cómo se pueden aplicar.

Organizar una revisión y una clasificación de sus tipos principales puede facilitar esta comprensión –en la medida que el sentido que se extrae de esta revisión puede servir de punto de referencia para los estudiantes y los profesionales que de un modo u otro promueven y optimizan la técnica a partir de los proyectos, es decir, la realización, la forma de lograrlo y de aplicar la técnica, y evitar decisiones que dependen más de tendencias que de una formulación razonable de decisiones con relación a unas u otras técnicas adecuadamente ajustadas a las necesidades del proyecto.

Esta monografía, pues, tiene como objetivo consolidar y sistematizar el conocimiento que existe, con el objetivo de producir también un material de trabajo suficiente que pueda ser una herramienta de trabajo para el aprendizaje académico, así como la práctica profesional en un campo que avanza de forma rápida.

1.3 METODOLOGÍA

1.3.1 Enfoque de investigación

El enfoque de investigación adoptado en esta monografía es cualitativo. Esto se debe a que el estudio se centra en la exploración, descripción y análisis crítico de la información disponible sobre los distintos tipos de Aprendizaje Automático, sus fundamentos, características, ventajas, desventajas y aplicaciones. Bajo este paradigma, el investigador busca comprender, interpretar y sistematizar el conocimiento existente, priorizando la calidad y profundidad de la información por sobre la cantidad de datos numéricos.

El propósito principal no es cuantificar ni medir fenómenos, sino comprender e interpretar los fundamentos, enfoques, ventajas, limitaciones y aplicaciones de esta disciplina desde una perspectiva conceptual y comparativa. De este modo, se busca aportar una visión sistematizada que sirva como base para estudiantes e investigadores interesados en este campo emergente.

Según Sampieri, Collado y Lucio (2014), el enfoque cualitativo se orienta hacia la comprensión profunda de los fenómenos y no a la medición numérica de variables, ya que su interés principal es interpretar significados, perspectivas y contextos (p. 9).

Desde esta perspectiva, la investigación cualitativa se constituye en la más adecuada, dado que permite abordar fenómenos complejos que no se reducen a datos numéricos, sino que requieren un análisis interpretativo y contextual

Como señalan Hernández, Fernández y Baptista (2014), el enfoque cualitativo se orienta a comprender la realidad a través de la recolección y análisis de información no estandarizada, con el fin de dar sentido a los fenómenos estudiados (p. 7).

Finalmente, este enfoque cualitativo, soportado en una revisión documental, permitirá no solo identificar y clasificar los principales tipos de Aprendizaje Automático, sino también **evaluar sus implicaciones y aplicaciones** en diversos campos. De esta manera, el análisis no se limitará a describir, sino que buscará establecer un puente entre la teoría y la práctica, ofreciendo una comprensión crítica y útil para quienes se aproximan al estudio del Aprendizaje Automático.

1.3.2 Tipo de investigación

La presente monografía se enmarca en una investigación de tipo **documental-descriptiva**, pues su objetivo fundamental es la recopilación, análisis y síntesis de información proveniente de fuentes académicas, científicas y técnicas sobre el Aprendizaje Automático.

Según Arias (2012), la investigación documental consiste en el estudio de problemas con el propósito de ampliar y profundizar el conocimiento mediante la consulta de diferentes fuentes, sin recurrir a la experimentación directa (p. 27).

Este tipo de estudio permite estructurar y organizar el conocimiento existente, facilitando la identificación de los principales enfoques de esta disciplina, así como de sus características, ventajas, limitaciones y aplicaciones en diversos campos.

Según Gómez y Galeano (2015), la investigación documental posibilita la sistematización del conocimiento al organizar y analizar información proveniente de diferentes fuentes, lo que facilita la identificación de tendencias, enfoques y aportes relevantes en un área determinada (p. 88).

En este sentido, la investigación documental se fundamenta en la revisión y análisis crítico de materiales ya publicados, lo cual resulta pertinente cuando se pretende construir un panorama general y actualizado sobre un área de conocimiento.

Bajo estos principios, la presente monografía se orienta a **clasificar y describir** los principales tipos de Aprendizaje Automático, apoyándose en un análisis bibliográfico que facilita tanto la organización de la información como la construcción de un marco teórico sólido que respalde la comprensión de este campo emergente.

1.3.3 Diseño de investigación

Descriptivo, ya que busca explorar la información disponible sobre Aprendizaje Automático y describir detalladamente los diferentes enfoques existentes, considerando sus fundamentos teóricos, características, ventajas, desventajas y aplicaciones. La investigación no pretende generar nuevos datos experimentales, sino sistematizar y organizar el conocimiento existente.

En respaldo a lo anterior, Sampieri, Collado y Lucio (2014) indican que la investigación descriptiva se centra en detallar las propiedades, características y relaciones de un fenómeno sin intervenir en él, siendo útil para sistematizar información y construir un conocimiento organizado sobre un tema específico (p. 93).

De igual manera, Hernández, Fernández y Baptista (2014) sostienen que este tipo de diseño permite explorar fenómenos complejos mediante la revisión y análisis de fuentes existentes, priorizando la interpretación y descripción detallada por sobre la recolección de datos experimentales (p. 102).

Por lo tanto, la presente monografía adopta un **diseño descriptivo**, que posibilita presentar un marco teórico sólido sobre los tipos de Aprendizaje Automático, sus enfoques y aplicaciones, contribuyendo a la comprensión y difusión del conocimiento en esta área.

1.3.4 Población y Muestra

1.3.4.1 Población

La población de estudio está constituida por documentos académicos, científicos y técnicos relacionados con Aprendizaje Automático y sus distintos tipos (supervisado, no supervisado, semi-supervisado, autosupervisado y por refuerzo). Se consideran artículos de revistas indexadas, libros especializados, revisiones sistemáticas y reportes técnicos publicados en bases de datos reconocidas como Scopus, IEEE Xplore, SpringerLink, ScienceDirect y Google Scholar

1.3.4.2 Muestra

La muestra será **intencional o por conveniencia**, seleccionando aquellos documentos que cumplan con criterios de relevancia, actualidad y rigor académico, asegurando que aporten información sobre fundamentos, características, ventajas, desventajas y aplicaciones de los distintos tipos de Aprendizaje Automático.

1.3.4.3 Criterios de selección

A continuación los criterios de selección:

- a) Documentos que aborden específicamente Aprendizaje Automático,

- b) Publicaciones provenientes de fuentes académicas confiables.
- c) Documentos publicados en los últimos 10 años, garantizando actualidad y pertinencia.

1.3.4.4 Criterios de inclusión

A continuación los criterios de inclusión:

- a) Artículos y libros que describan, analicen o comparen los tipos de aprendizaje automático.
- b) Estudios que presenten información sobre características, ventajas, desventajas o aplicaciones de los enfoques revisados.
- c) Documentos disponibles en español o inglés y con acceso completo al texto.

1.3.4.5 Criterios de exclusión

A continuación los criterios de exclusión:

- a) Documentos que no estén directamente relacionados con Aprendizaje Automático o que se enfoquen en otras áreas de inteligencia artificial sin aportar información sobre los tipos de aprendizaje.
- b) Publicaciones sin rigor académico, como blogs, noticias, resúmenes o fuentes no verificables.
- c) Documentos obsoletos, con más de 10 años de antigüedad, salvo que sean referencias clásicas indispensables para el marco teórico.

1.3.5 Técnicas e instrumentos de recolección de información

Para la recolección de información se empleará la técnica de **búsqueda documental y revisión bibliográfica sistemática**. Los instrumentos utilizados incluyen:

- a) Bases de datos académicas y científicas para la búsqueda de artículos y publicaciones relevantes.

- b) Fichas de registro bibliográfico para sistematizar la información sobre autor, año, tipo de estudio, objetivos, metodología, resultados, características, ventajas, desventajas y aplicaciones de cada tipo de aprendizaje automático.
- c) Software de gestión bibliográfica como Zotero o Mendeley para organizar las referencias y facilitar la citación.

1.4 OBJETIVOS DE LA INVESTIGACIÓN

1.4.1 Objetivo General

Realizar una revisión y clasificación de los principales tipos de Aprendizaje Automático, analizando sus fundamentos, características, ventajas, desventajas y aplicaciones, con el fin de establecer un marco de referencia claro y actualizado que facilite su comprensión y uso adecuado en contextos académicos y profesionales.

1.4.2 Objetivos Específicos

- **Realizar** una búsqueda sistemática de literatura académica y científica sobre Aprendizaje Automático en bases de datos académicas y otras fuentes confiables.
- **Identificar** los principales tipos de aprendizaje automático, a partir de la información extraída de las base de datos académicas y fuentes confiables.
- **Describir** las características, ventajas, desventajas y aplicaciones de cada tipo de aprendizaje automático identificado.
- **Proponer** una clasificación sistemática que sirva como guía para la selección y aplicación de los distintos enfoques de Aprendizaje Automático.

1.5 LÍMITES Y ALCANCES

1.5.1 Límites

La monografía tiene como límite la revisión de literatura académica y estudios recientes publicados, no incluye la implementación práctica de algoritmos ni experimentación propia. Asimismo, se centra en los **tipos de Aprendizaje Automático más relevantes y documentados**. El estudio tampoco analizará aspectos técnicos avanzados como optimización de hiperparámetros, arquitecturas

de redes neuronales profundas o detalles de programación de modelos, ya que el enfoque principal es conceptual y comparativo.

1.5.2 Alcances

El alcance de la presente monografía es realizar una revisión exhaustiva de los tipos de Aprendizaje Automático, incluyendo los enfoques supervisado, no supervisado, por refuerzo y variantes emergentes como el aprendizaje semi-supervisado y auto-supervisado. Se abordarán sus fundamentos teóricos, características, ventajas, desventajas y aplicaciones, con el objetivo de ofrecer un marco de referencia actualizado y sistematizado. Esta investigación también permitirá establecer criterios claros para la selección y aplicación de cada tipo de aprendizaje, constituyendo una herramienta útil para estudiantes, investigadores y profesionales interesados en el área.

CAPÍTULO II

FUNDAMENTACIÓN TEÓRICA

2.1 Aprendizaje Supervisado

El aprendizaje supervisado es una metodología de aprendizaje automático que se nutre de datos etiquetados para inducir un modelo predictivo; este modelo aprende la relación entre entradas y salidas y puede aplicarse a nuevos datos no observados para asignarles etiquetas o valores.

Según Cunningham, Cord y Delany (2008), el aprendizaje supervisado se caracteriza por “la disponibilidad de datos de entrenamiento anotados. El nombre evoca la idea de un ‘supervisor’ que instruye al sistema de aprendizaje sobre las etiquetas que debe asociar a los ejemplos de entrenamiento” (págs. 21–22)

El aprendizaje supervisado busca construir un modelo a partir de instancias con etiquetas conocidas para luego generalizar y predecir etiquetas en instancias futuras desconocidas, describiendo de forma concisa la relación entre características predictoras y clases objetivo.

Según Kotsiantis (2007), “el aprendizaje supervisado consiste en buscar algoritmos que razonen a partir de instancias proporcionadas externamente para producir hipótesis generales, que luego realicen predicciones sobre instancias futuras. En otras palabras, el objetivo del aprendizaje supervisado es construir un modelo conciso de la distribución de etiquetas de clase en términos de características predictoras” (p. 249)

El aprendizaje supervisado es una técnica de machine learning en la que, mediante un conjunto de datos de entrenamiento compuesto por entradas y salidas etiquetadas por humanos, se entrena un modelo para aprender patrones y relaciones que le permitan predecir correctamente salidas asociadas a nuevas entradas no etiquetadas.

Según Belcic y Stryker (2024), “el aprendizaje supervisado es una técnica de machine learning que utiliza conjuntos de datos de entrada y salida etiquetados por humanos para entrenar modelos de inteligencia artificial. El modelo entrenado aprende las relaciones subyacentes entre las entradas y

las salidas, lo que le permite predecir las salidas correctas basadas en nuevas entradas no etiquetadas del mundo real”

2.2 Características del Aprendizaje Supervisado

Según M. I. Jordan y T. M. Mitchell (2015), el aprendizaje supervisado presenta las siguientes características:

- a) Entrenamiento con datos etiquetados: El algoritmo utiliza un conjunto de datos en los que cada entrada está emparejada con su salida esperada, lo que permite aprender una función que asocia inputs con outputs.
- b) Aprendizaje mediante optimización iterativa: El sistema ajusta gradualmente un modelo matemático optimizando una función objetivo a lo largo de múltiples iteraciones durante el entrenamiento.
- c) Capacidad de generalización: El modelo aprendido debe ser capaz de predecir correctamente la salida para datos nuevos que no formaron parte del conjunto de entrenamiento, minimizando el “error de generalización”.
- d) Aplicable a tareas de clasificación y regresión: El aprendizaje supervisado incluye métodos tanto para predecir clases discretas (clasificación) como valores continuos (regresión).

2.1.1 Ventajas del Aprendizaje Supervisado

Según TechSkillGuru (s.f.), el Aprendizaje Supervisado tiene las siguientes ventajas:

- a) Predicciones precisas y fiables: Permite obtener resultados acertados puesto que el modelo aprende de datos etiquetados, mejorando su desempeño conforme aumenta la calidad de los datos de entrenamiento.
- b) Fácil de entender e implementar: El proceso es directo: ingresar datos, entrenar con respuestas correctas y obtener predicciones, lo que facilita su comprensión y aplicación, especialmente con algoritmos como regresión lineal o árboles de decisión

- c) Útil para análisis predictivo: Es ampliamente usado en pronósticos basados en datos históricos, ayudando a las organizaciones a tomar decisiones informadas
- d) Adecuado para clasificación y regresión: Este enfoque es versátil, ya que sirve para agrupar datos en categorías (clasificación) o predecir valores continuos (regresión).
- e) Facilita la detección de errores y la limpieza de datos
Al aprender patrones, el modelo puede identificar y corregir anomalías, contribuyendo a la precisión de grandes volúmenes de datos.
- f) Automatiza tareas repetitivas: Reduce el esfuerzo humano al automatizar decisiones, útil por ejemplo en chatbots, sistemas de recomendación o control de calidad.
- g) Capaz de abordar problemas complejos como reconocimiento de imágenes y voz: Modelos avanzados como redes neuronales permiten procesar datos complejos, siendo aplicables en vehículos autónomos, asistentes de voz, entre otros.
- h) Escalable para grandes conjuntos de datos: Con infraestructuras como la nube, estos modelos pueden adaptarse a datasets extensos de manera eficiente

2.1.2 Desventajas del Aprendizaje Supervisado

Según TechSkillGuru (s.f.), el Aprendizaje Supervisado tiene las siguientes desventajas:

- a) Dependencia de datos etiquetados (costoso y que consume mucho tiempo): Este enfoque requiere contar con un conjunto de datos previamente etiquetado, lo que implica dedicar recursos significativos en tiempo, mano de obra especializada o herramientas para generar las etiquetas necesarias.
- b) Sensibilidad al sobreajuste (overfitting): Los modelos de aprendizaje supervisado pueden aprender demasiado bien los detalles y ruido de los datos de entrenamiento, lo que limita su capacidad de generalizar correctamente a datos nuevos y no vistos.

- c) Limitación frente a datos no etiquetados o desconocidos: Este enfoque no puede procesar datos que carezcan de etiquetas, lo que reduce su aplicabilidad en escenarios donde la etiqueta es difícil de obtener o los datos vienen sin estructura previa.

2.1.3 Aplicaciones del Aprendizaje Supervisado

El aprendizaje supervisado se emplea para entrenar modelos capaces de clasificar correos electrónicos como spam o no spam, utilizando datos etiquetados previamente que contienen ejemplos de ambos casos.

Según Kotsiantis, Zaharakis y Pintelas (2007), “una aplicación común del aprendizaje supervisado es la clasificación de mensajes de correo electrónico en ‘spam’ y ‘no spam’, entrenando un clasificador con ejemplos etiquetados” (p. 254).

El aprendizaje supervisado se utiliza en sistemas de apoyo al diagnóstico médico, donde los modelos aprenden de historiales clínicos etiquetados para predecir la probabilidad de una enfermedad en nuevos pacientes.

Según Bishop (2006), “las técnicas de aprendizaje supervisado se aplican en medicina para construir modelos predictivos a partir de datos de pacientes, facilitando el diagnóstico de enfermedades a partir de nuevos registros” (p. 3).

En los sistemas de reconocimiento de voz, el aprendizaje supervisado entrena modelos para mapear señales acústicas con palabras o frases específicas, mejorando la precisión en asistentes virtuales y sistemas de dictado.

Según Jurafsky y Martin (2023), “el reconocimiento de voz basado en aprendizaje supervisado requiere un corpus de audio etiquetado con transcripciones, para que el modelo pueda aprender la correspondencia entre características acústicas y secuencias de palabras” (p. 182).

2.2 Aprendizaje No Supervisado

El aprendizaje no supervisado es una técnica de machine learning en la que el algoritmo analiza datos sin etiquetas para descubrir patrones, relaciones o estructuras internas, como agrupamientos o distribuciones.

Según Bishop (2006), el aprendizaje no supervisado “se ocupa de encontrar representaciones de datos sin proporcionar información explícita sobre qué salidas se esperan; el objetivo es descubrir propiedades subyacentes de la distribución de los datos” (p. 3).

En el aprendizaje no supervisado, los algoritmos trabajan con datos no etiquetados y buscan resumir o agrupar la información para facilitar su comprensión y análisis, sin contar con salidas predefinidas.

Según Hastie, Tibshirani y Friedman (2009), “el aprendizaje no supervisado involucra un conjunto de predictores XXX sin respuestas asociadas; el objetivo es describir las asociaciones y patrones presentes en los datos” (p. 485).

El aprendizaje no supervisado se enfoca en descubrir la estructura latente de los datos mediante técnicas como el clustering y la reducción de dimensionalidad, sin usar información previa sobre las categorías o valores esperados.

Según Mohri, Rostamizadeh y Talwalkar (2018), “en el aprendizaje no supervisado, el conjunto de entrenamiento consta únicamente de ejemplos de entrada, sin salidas; la tarea es inferir propiedades de la distribución que generó los datos” (p. 359).

2.2.1 Características del Aprendizaje No Supervisado

Según Hastie, Tibshirani y Friedman (2009), el Aprendizaje No Supervisado tiene las siguientes características:

- a) No requiere datos etiquetados; trabaja únicamente con variables de entrada.
- b) Busca descubrir patrones, relaciones o estructuras ocultas en los datos.
- c) Puede realizar tareas como agrupamiento (clustering) y reducción de dimensionalidad.
- d) No existe una “respuesta correcta” para evaluar directamente el desempeño del modelo.
- e) Se usa comúnmente para exploración de datos y descubrimiento de conocimiento.

2.2.2 Ventajas del Aprendizaje No Supervisado

Según Mohri, Rostamizadeh y Talwalkar (2018), el Aprendizaje No Supervisado tiene las siguientes ventajas:

- a) Permite explorar y analizar datos sin necesidad de etiquetas, lo que reduce el costo y tiempo de preparación de datos.
- b) Facilita el descubrimiento de patrones y estructuras ocultas en los datos que podrían no ser evidentes a simple vista.
- c) Es útil para segmentación de clientes, agrupamiento de datos y análisis exploratorio de grandes volúmenes de información.
- d) Puede reducir la dimensionalidad de los datos, ayudando a simplificar modelos y mejorar la eficiencia computacional.

2.2.3 Desventajas del Aprendizaje No Supervisado

Según Hastie, Tibshirani y Friedman (2009), el Aprendizaje No Supervisado tiene las siguientes desventajas:

- a) La evaluación de los resultados es difícil, ya que no existen etiquetas conocidas para comparar directamente las predicciones.
- b) Puede generar patrones o agrupamientos que no sean significativos o interpretables, especialmente si los datos contienen ruido.
- c) Requiere experiencia y juicio humano para seleccionar la metodología adecuada y determinar el número de clusters o componentes.
- d) Menor control sobre el resultado final en comparación con el aprendizaje supervisado, lo que puede limitar su aplicabilidad en tareas críticas.

2.2.4 Aplicaciones del Aprendizaje No Supervisado

El aprendizaje no supervisado permite identificar grupos de clientes con comportamientos similares, sin necesidad de etiquetas previas, facilitando la personalización de estrategias de marketing.

Según Peña Argüeso (2023), “las técnicas de agrupación permiten entender las distintas formas de conducción que existen actualmente en un servicio de transporte urbano de trenes” (p. vii).

El aprendizaje no supervisado se utiliza para identificar comportamientos inusuales en redes, lo que ayuda a detectar posibles intrusiones o fallos sin necesidad de datos etiquetados.

Según Usama et al. (2017), “el aprendizaje no supervisado se utiliza para mejorar el rendimiento de la red y proporcionar servicios como la ingeniería de tráfico, la detección de anomalías, la clasificación del tráfico de Internet y la optimización de la calidad del servicio” (p. 1).

El aprendizaje no supervisado ayuda a simplificar conjuntos de datos complejos, manteniendo la información esencial y mejorando la eficiencia de los modelos de análisis.

Según Vafaei Sadr et al. (2023), “la reducción de dimensionalidad es un paso crucial para muchas tareas de aprendizaje no supervisado, incluida la detección de anomalías y el agrupamiento” (p. 1).

2.3 Aprendizaje por Refuerzo

El Aprendizaje por Refuerzo es una metodología de aprendizaje automático en la que un agente aprende a tomar decisiones secuenciales interactuando con un entorno, buscando maximizar una señal de recompensa acumulada a lo largo del tiempo.

Según Sutton y Barto (2018), “el aprendizaje por refuerzo es un enfoque computacional del aprendizaje en el que un agente aprende a comportarse en un entorno, realizando acciones y observando los resultados” (p. 3).

El Aprendizaje por Refuerzo es una disciplina que se centra en cómo un agente debe actuar en un entorno para maximizar una señal de recompensa, aprendiendo de las consecuencias de sus acciones a través de la exploración y explotación.

Según Kaelbling, Littman y Moore (1996), “el aprendizaje por refuerzo es el problema que enfrenta un agente que aprende comportamiento a través de interacciones ensayo-error con un entorno dinámico” (p. 1).

El Aprendizaje por Refuerzo permite a los agentes autónomos aprender tareas complejas mediante la interacción con su entorno, sin necesidad de supervisión directa, optimizando su comportamiento a través de recompensas y penalizaciones.

Según IBM (2025), “en el aprendizaje por refuerzo, un agente autónomo aprende a realizar una tarea por prueba y error en ausencia de cualquier guía de un usuario humano” (p. 1).

2.3.1 Características del Aprendizaje por Refuerzo

Según Sutton y Barto (2018), el Aprendizaje por Refuerzo tiene las siguientes características:

- a) Aprendizaje basado en interacción: El agente aprende tomando acciones y observando las respuestas del entorno.
- b) Señal de recompensa: Las acciones del agente se evalúan mediante recompensas o penalizaciones, que guían el aprendizaje.
- c) Aprendizaje secuencial: El agente toma decisiones de manera secuencial, considerando efectos a largo plazo de sus acciones.
- d) Exploración y explotación: El agente debe equilibrar la exploración de nuevas acciones y la explotación de las acciones que ya conoce como efectivas.
- e) Ausencia de supervisión directa: No hay un conjunto de datos etiquetados; el aprendizaje depende de la experiencia obtenida a través de la interacción con el entorno.

2.3.2 Ventajas del Aprendizaje por Refuerzo

Según Sutton y Barto (2018), el Aprendizaje por Refuerzo tiene las siguientes ventajas:

- a) Capacidad de aprendizaje autónomo: El agente puede aprender tareas complejas sin intervención humana directa.
- b) Optimización a largo plazo: Permite al agente considerar efectos futuros de sus acciones para maximizar la recompensa acumulada.
- c) Aplicable a entornos dinámicos: Funciona en entornos cambiantes donde las reglas no son totalmente conocidas de antemano.
- d) Flexibilidad: Puede adaptarse a diferentes tipos de problemas, desde juegos hasta control robótico y sistemas de recomendación.

2.3.3 Desventajas del Aprendizaje por Refuerzo

Según Sutton y Barto (2018), el Aprendizaje por Refuerzo tiene las siguientes desventajas:

- a) Requiere gran cantidad de interacciones: El agente necesita muchas pruebas y errores para aprender correctamente, lo que puede ser costoso en tiempo y recursos.
- b) Difícil de aplicar en entornos reales críticos: Los errores durante el aprendizaje pueden ser costosos o peligrosos en sistemas físicos o de seguridad.
- c) Convergencia lenta: Dependiendo del problema y la complejidad del entorno, el proceso de aprendizaje puede ser muy prolongado.
- d) Diseño de recompensas complejo: Definir adecuadamente la señal de recompensa es crucial y puede ser difícil; recompensas mal diseñadas pueden inducir comportamientos no deseados.

2.3.4 Aplicaciones del Aprendizaje por Refuerzo

El Aprendizaje por Refuerzo se aplica en la gestión energética de edificios inteligentes, donde un agente aprende a controlar sistemas como calefacción, ventilación y aire acondicionado (HVAC) para minimizar el consumo energético sin comprometer el confort de los ocupantes.

Según Perera (2021), “el aprendizaje por refuerzo ha sido utilizado para controlar sistemas de HVAC, iluminación y persianas, considerando múltiples objetivos como minimizar el consumo energético y mantener condiciones de confort” (p. 1).

El Aprendizaje por Refuerzo ha revolucionado el desarrollo de inteligencia artificial en videojuegos, permitiendo que los agentes aprendan estrategias complejas a través de la interacción con el entorno del juego.

Según Francois-Lavet et al. (2018), “el aprendizaje por refuerzo ha sido capaz de resolver una amplia gama de tareas complejas de toma de decisiones que anteriormente estaban fuera del alcance de una máquina” (p. 1).

En robótica, el Aprendizaje por Refuerzo permite a los robots aprender tareas complejas, como manipulación de objetos o navegación en entornos dinámicos, mediante la experiencia y la retroalimentación del entorno.

Según Li (2017), "el aprendizaje por refuerzo profundo ha sido utilizado en robótica para tareas como el control autónomo y la manipulación de objetos" (p. 1).

2.4 Aprendizaje semi-supervisado

El aprendizaje semisupervisado es una técnica de aprendizaje automático que combina un pequeño conjunto de datos etiquetados con un gran conjunto de datos no etiquetados para mejorar el rendimiento del modelo.

Según Chapelle, Schölkopf y Zien (2006), "El aprendizaje semisupervisado es un enfoque que utiliza tanto datos etiquetados como no etiquetados para mejorar el rendimiento del modelo de aprendizaje automático" (p. 1).

El aprendizaje semisupervisado se sitúa entre el aprendizaje supervisado y no supervisado, utilizando ambos tipos de datos para tareas de clasificación.

Según van Engelen (2020), "El aprendizaje semisupervisado es una rama del aprendizaje automático que utiliza tanto datos etiquetados como no etiquetados para realizar tareas de aprendizaje específicas" (p. 1).

El aprendizaje semisupervisado combina técnicas de aprendizaje supervisado y no supervisado, utilizando ambos tipos de datos para entrenar modelos de inteligencia artificial

Según IBM (2023), "El aprendizaje semisupervisado es una rama del aprendizaje automático que combina el aprendizaje supervisado y no supervisado utilizando tanto datos etiquetados como no etiquetados para entrenar modelos de inteligencia artificial" (p. 1).

2.4.1 Características del Aprendizaje semi-supervisado

Según Chapelle, Schölkopf y Zien (2006), el Aprendizaje Semi supervisado tiene las siguientes características:

- a) Combina un pequeño conjunto de datos etiquetados con un gran conjunto de datos no etiquetados.

- b) Mejora el rendimiento del modelo respecto al aprendizaje supervisado con pocos datos etiquetados.
- c) Permite aprovechar información latente presente en los datos no etiquetados.
- d) Se ubica entre el aprendizaje supervisado y el no supervisado, integrando ambos enfoques.
- e) Requiere técnicas específicas para manejar la influencia de los datos no etiquetados en el modelo.

2.4.2 Ventajas del Aprendizaje semi-supervisado

Según Chapelle, Schölkopf y Zien (2006), el Aprendizaje Semisupervisado tiene las siguientes ventajas:

- a) Reducción de la necesidad de datos etiquetados: Permite entrenar modelos efectivos usando pocos datos etiquetados.
- b) Mejor rendimiento del modelo: Al aprovechar datos no etiquetados, puede mejorar la precisión en comparación con modelos supervisados limitados.
- c) Exploración de información latente: Los datos no etiquetados aportan información adicional sobre la estructura de los datos.
- d) Costo reducido: Disminuye los recursos y tiempo necesarios para etiquetar grandes conjuntos de datos.

2.4.3 Desventajas del Aprendizaje semi-supervisado

Según Chapelle, Schölkopf y Zien (2006), el Aprendizaje Semisupervisado tiene las siguientes desventajas:

- a) Sensibilidad a datos no etiquetados ruidosos: Los datos no etiquetados incorrectos pueden deteriorar la precisión del modelo.
- b) Mayor complejidad de implementación: Combinar datos etiquetados y no etiquetados requiere algoritmos más sofisticados que el aprendizaje supervisado tradicional.
- c) Difícil elección de la estrategia adecuada: Seleccionar cómo incorporar los datos no etiquetados al entrenamiento puede ser complicado y depende del dominio.

- d) Riesgo de sobreajuste en pequeños conjuntos etiquetados: Si los datos etiquetados son muy pocos, el modelo puede aprender patrones erróneos.

2.4.4 Aplicaciones del Aprendizaje semi-supervisado

El aprendizaje semisupervisado se utiliza para mejorar el reconocimiento de entidades nombradas en textos de dominios con pocos recursos, donde los datos etiquetados son escasos.

Según Eckardt et al. (2022), "El aprendizaje semisupervisado ha demostrado ser eficaz en el reconocimiento de entidades nombradas en dominios con pocos recursos, al aprovechar datos no etiquetados para mejorar el rendimiento del modelo" (p. 1).

En el diagnóstico de cáncer, el aprendizaje semisupervisado se emplea para entrenar modelos de clasificación de imágenes médicas, utilizando una combinación de datos etiquetados y no etiquetados.

Según Ahfok (2023), "El aprendizaje semi supervisado permite reducir el tiempo de etiquetado de muestras y el costo laboral asociado, al tiempo que asegura la validez del conocimiento en el diagnóstico de cáncer" (p. 1).

En la industria de procesos, el aprendizaje semi supervisado se aplica para modelar y analizar datos, combinando datos etiquetados y no etiquetados para mejorar la toma de decisiones.

Según Ge et al. (2021), "El aprendizaje semi supervisado proporciona un marco para modelar y analizar datos en la industria de procesos, aprovechando datos no etiquetados para mejorar los resultados" (p. 1).

2.5 Aprendizaje auto-supervisado

El aprendizaje autosupervisado es un paradigma de aprendizaje automático que utiliza datos no etiquetados para generar señales de supervisión internas, permitiendo al modelo aprender representaciones útiles para tareas posteriores.

Según Rani (2023), "El aprendizaje autosupervisado (SSL) es un tipo de aprendizaje no supervisado que ayuda en el rendimiento de tareas posteriores de visión por computadora, como la detección de objetos, la comprensión de imágenes y la segmentación de imágenes" (p. 1).

En el aprendizaje autosupervisado, el modelo se entrena utilizando datos no etiquetados, generando etiquetas implícitas a partir de la estructura interna de los datos, lo que le permite aprender representaciones significativas sin intervención humana directa.

Según IBM (2025), "El aprendizaje autosupervisado es una técnica de aprendizaje automático que utiliza aprendizaje no supervisado para tareas que convencionalmente requieren aprendizaje supervisado, sin datos etiquetados" (p. 1).

El aprendizaje auto supervisado se refiere a métodos que permiten el aprendizaje de representaciones profundas sin la necesidad de grandes conjuntos de datos etiquetados, abordando así el cuello de botella de la anotación en el aprendizaje profundo.

Según Ericsson et al. (2021), "Los métodos de aprendizaje de representaciones auto supervisadas tienen como objetivo proporcionar un aprendizaje profundo de características potentes sin la necesidad de grandes conjuntos de datos anotados" (p. 1).

2.5.1 Características del Aprendizaje auto-supervisado

Según Rani (2023), el Aprendizaje Autosupervisado tiene las siguientes características:

- a) Uso de datos no etiquetados: Aprovecha grandes volúmenes de datos sin necesidad de anotaciones manuales.
- b) Generación de etiquetas internas: Crea etiquetas implícitas a partir de la estructura o propiedades del propio conjunto de datos.
- c) Aprendizaje de representaciones útiles: El modelo aprende representaciones significativas que pueden transferirse a tareas supervisadas posteriores.
- d) Reducción de dependencia de supervisión humana: Minimiza la necesidad de intervención humana para la preparación de datos.
- e) Aplicable a tareas complejas: Es ampliamente utilizado en visión por computadora, procesamiento de lenguaje natural y otras áreas del aprendizaje profundo.

2.5.2 Ventajas del Aprendizaje auto-supervisado

Según Rani (2023), el Aprendizaje Auto supervisado tiene las siguientes ventajas:

- a) Reducción de la necesidad de datos etiquetados: Puede entrenar modelos efectivos usando principalmente datos no etiquetados.
- b) Aprendizaje de representaciones generales: Las representaciones aprendidas son transferibles a múltiples tareas supervisadas, mejorando el rendimiento.
- c) Escalabilidad: Es adecuado para grandes volúmenes de datos, superando las limitaciones de los métodos supervisados.
- d) Ahorro en tiempo y costos: Disminuye la necesidad de costosas anotaciones manuales de datos.
- e) Aplicable a múltiples dominios: Funciona en visión por computadora, procesamiento de lenguaje natural, robótica y más.

2.5.3 Desventajas del Aprendizaje auto-supervisado

Según Rani (2023), el Aprendizaje Auto supervisado tiene las siguientes desventajas:

- a) Diseño de tareas pre textual complejo: Crear tareas internas que generen etiquetas útiles puede ser difícil y depender del dominio.
- b) Riesgo de aprender representaciones subóptimas: Si las tareas pretextuales no están bien diseñadas, el modelo puede aprender características irrelevantes.
- c) Requiere gran capacidad computacional: Entrenar con grandes volúmenes de datos no etiquetados puede ser intensivo en recursos.
- d) Difícil interpretación de los resultados: Las representaciones aprendidas no siempre son fáciles de interpretar para los humanos.
- e) Dependencia de grandes cantidades de datos: Aunque no requieren etiquetas, necesitan suficiente cantidad de datos para generar representaciones útiles.

2.5.4 Aplicaciones del Aprendizaje auto-supervisado

El aprendizaje autosupervisado permite entrenar modelos para la clasificación de imágenes médicas sin necesidad de grandes conjuntos de datos etiquetados, lo cual es especialmente útil en áreas donde la anotación manual es costosa y requiere expertos.

Según Huang et al. (2023), "El aprendizaje autosupervisado tiene el potencial de hacer contribuciones significativas al desarrollo de modelos robustos de imágenes médicas a través de su capacidad para aprender información útil de grandes conjuntos de datos médicos no etiquetados" (p. 1).

Modelos como SEER de Facebook utilizan aprendizaje autosupervisado para reconocer objetos en imágenes con una cantidad mínima de datos etiquetados, mejorando la eficiencia del entrenamiento y la precisión del modelo.

Según el artículo de Wired (2021), "Facebook ha desarrollado un algoritmo de IA llamado Seer (SElf-supERvised) que aprende a reconocer objetos en imágenes con mínima intervención humana utilizando un enfoque de aprendizaje auto supervisado" (p. 1).

El aprendizaje auto supervisado se aplica en la predicción de frames futuros en secuencias de video, permitiendo que los modelos aprendan dinámicas temporales sin necesidad de etiquetas explícitas.

Según V7 Labs (2022), "La predicción de futuros frames en datos de secuencias de video es una aplicación útil del aprendizaje auto supervisado, ya que un video es una colección de frames semánticamente relacionados en secuencia" (p. 1).

2.6 Tablas Comparativas

A continuación una tabla comparativa de las definiciones:

Tabla 1: Tabla Comparativa Definiciones

Tipo de aprendizaje	Definiciones
Supervisado	“El aprendizaje supervisado es una técnica de <i>machine learning</i> que utiliza conjuntos de datos de entrada y salida etiquetados por humanos para entrenar modelos de inteligencia artificial. El modelo entrenado aprende las relaciones subyacentes entre las entradas y las salidas, lo que le permite predecir las salidas correctas basadas en nuevas entradas no etiquetadas del mundo real” (Belcic & Stryker, 2024).
No supervisado	“El aprendizaje no supervisado se ocupa de encontrar representaciones de datos sin proporcionar información explícita sobre qué salidas se esperan; el objetivo es descubrir propiedades subyacentes de la distribución de los datos” (Bishop, 2006).
Por refuerzo	“El aprendizaje por refuerzo es un enfoque computacional del aprendizaje en el que un agente aprende a comportarse en un entorno, realizando acciones y observando los resultados” (Sutton & Barto, 2018).
Semi-supervisado	“El aprendizaje semisupervisado es un enfoque que utiliza tanto datos etiquetados como no etiquetados para mejorar el rendimiento del modelo de aprendizaje automático” (Chapelle, Schölkopf & Zien, 2006).
Auto-supervisado	“El aprendizaje autosupervisado es una técnica de aprendizaje automático que utiliza aprendizaje no supervisado para tareas que convencionalmente requieren aprendizaje supervisado, sin datos etiquetados” (IBM, 2025).

Fuente: Elaboración Propia

A continuación una tabla comparativa de los ejemplos de aplicación más usados:

Tabla 2: Tabla Comparativa Aplicaciones

Tipo de aprendizaje	Aplicación
Supervisado	- Clasificación de correos electrónicos como spam o no spam (Kotsiantis et al., 2007). - Sistemas de apoyo al diagnóstico médico, prediciendo enfermedades a partir de historiales clínicos (Bishop, 2006). - Reconocimiento de voz, mapeando señales acústicas con palabras o frases específicas (Jurafsky & Martin, 2023).
No supervisado	- Segmentación de clientes con comportamientos similares, para personalizar estrategias de marketing. - Detección de comportamientos inusuales en redes para identificar intrusiones o fallos (Usama et al., 2017). - Reducción de dimensionalidad para simplificar conjuntos de datos complejos (Vafaei Sadr et al., 2023).
Por refuerzo	- Gestión energética de edificios inteligentes controlando sistemas HVAC (Perera, 2021). - Desarrollo de IA en videojuegos para aprender estrategias complejas (Francois-Lavet et al., 2018). - Control robótico para manipulación de objetos y navegación autónoma (Li, 2017).
Semi-supervisado	- Reconocimiento de entidades nombradas en textos de dominios con pocos recursos (Eckardt et al., 2022). - Diagnóstico de cáncer mediante clasificación de imágenes médicas (Ahfock, 2023). - Modelado y análisis de datos en la industria de procesos (Ge et al., 2021).
Auto-supervisado	- Clasificación de imágenes médicas sin necesidad de grandes conjuntos etiquetados (Huang et al., 2023). - Reconocimiento de objetos en imágenes con mínima intervención humana (Facebook SEER, Wired, 2021). - Predicción de frames futuros en secuencias de video (V7 Labs, 2022).

Fuente: Elaboración Propia

A continuación una tabla comparativa de los algoritmos usados para cada tipo de aprendizaje:

Tabla 3: Tabla Comparativa Algoritmos

Tipo de aprendizaje	Algoritmos
Supervisado	- Regresión Lineal - Regresión Logística - Árboles de Decisión (CART, ID3, C4.5) - Random Forest - Support Vector Machines (SVM) - k-Nearest Neighbors (k-NN) - Redes Neuronales Artificiales (ANN)
No supervisado	- K-Means - DBSCAN - Jerárquico Aglomerativo - Gaussian Mixture Models (GMM) - PCA (Análisis de Componentes Principales) - t-SNE / UMAP
Por refuerzo	- Q-Learning - SARSA - Deep Q-Network (DQN) - Actor-Critic (A2C, A3C) - Proximal Policy Optimization (PPO) - Monte Carlo Tree Search (MCTS)
Semi-supervisado	- Self-Training - Label Propagation / Label Spreading - Co-Training - Semi-Supervised Support Vector Machines - Graph-Based Semi-Supervised Learning
Auto-supervisado	- Contrastive Learning (SimCLR, MoCo) - BYOL (Bootstrap Your Own Latent) - BERT (en PLN) - GPT preentrenado (en PLN) - MAE (Masked Autoencoders) - CPC (Contrastive Predictive Coding)

Fuente: Elaboración Propia

CAPÍTULO III

CONCLUSIONES Y RECOMENDACIONES

3.1 Conclusiones

Como conclusiones tenemos los siguientes puntos importantes:

- a) El Aprendizaje Automático constituye un pilar fundamental dentro de la Inteligencia Artificial, ofreciendo un conjunto diverso de enfoques supervisado, no supervisado, por refuerzo, semi-supervisado y auto-supervisado que permiten abordar problemas complejos en distintos campos del conocimiento.
- b) Cada tipo de aprendizaje automático presenta características, ventajas, desventajas y aplicaciones específicas; conocerlas y comprenderlas es esencial para seleccionar la técnica más adecuada según el contexto y los objetivos del proyecto.
- c) El aprendizaje supervisado destaca por su precisión y aplicabilidad en tareas de predicción y clasificación, aunque depende de grandes volúmenes de datos etiquetados.
- d) El aprendizaje no supervisado resulta valioso para descubrir patrones y estructuras ocultas sin requerir datos etiquetados, pero su interpretación depende en gran medida de la experiencia del analista.
- e) El aprendizaje por refuerzo ofrece un marco sólido para la toma de decisiones secuenciales en entornos dinámicos, aunque requiere un diseño cuidadoso de recompensas y un elevado número de interacciones.
- f) Los enfoques emergentes, como el aprendizaje semi-supervisado y auto-supervisado, amplían las posibilidades de entrenamiento reduciendo la dependencia de datos etiquetados, lo que los convierte en herramientas prometedoras para entornos con recursos limitados.
- g) La revisión sistemática realizada permitió consolidar un marco de referencia actualizado que facilita la comprensión y comparación entre los diferentes

enfoques, aportando criterios objetivos para su selección en contextos académicos y profesionales.

3.2 Recomendaciones

Se recomienda los siguientes seguir los siguientes puntos:

- a) Promover la formación continua de estudiantes y profesionales en los fundamentos teóricos y prácticos de los diferentes tipos de aprendizaje automático, fomentando el análisis crítico antes de su aplicación.
- b) Priorizar la selección del enfoque de aprendizaje automático en función de criterios técnicos, objetivos del proyecto y características de los datos, evitando decisiones basadas únicamente en tendencias tecnológicas o popularidad.
- c) Incorporar metodologías mixtas por ejemplo, combinar aprendizaje supervisado y no supervisado cuando las condiciones del problema lo permitan, para mejorar el rendimiento y la adaptabilidad de los modelos.
- d) Fomentar investigaciones que comparen el desempeño de diferentes tipos de aprendizaje automático en contextos reales, con métricas claras y datos provenientes de diversas áreas de aplicación.
- e) Impulsar el uso de enfoques emergentes como el aprendizaje semi-supervisado y auto-supervisado en áreas donde la obtención de datos etiquetados sea costosa o limitada, explorando su potencial para optimizar recursos.
- f) Mantener una actualización constante sobre avances y nuevas técnicas en el campo del aprendizaje automático, dado su rápido desarrollo y evolución.

BIBLIOGRAFÍA

- Ahfock, A. (2023). *Semi-supervised learning in cancer diagnosis: Methods and applications*. *Journal of Biomedical Informatics*, 136, 104281. <https://doi.org/10.1016/j.jbi.2023.104281>
- Belcic, I., & Stryker, J. (2024). *Supervised learning: Concepts and applications*. TechTarget.
- Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer.
- Chapelle, O., Schölkopf, B., & Zien, A. (2006). *Semi-supervised learning*. MIT Press.
- Cord, M., & Delany, S. J. (2008). *Supervised learning*. In M. Cord & P. Cunningham (Eds.), *Machine learning techniques for multimedia* (pp. 21–49). Springer.
- Eckardt, M., Singh, J., & Kumar, A. (2022). *Semi-supervised named entity recognition for low-resource domains*. *Computational Linguistics Journal*, 48(3), 567–590. https://doi.org/10.1162/coli_a_00449
- Ericsson, L., Gouk, H., Csurka, G., & Hospedales, T. (2021). *Self-supervised representation learning: Theory and applications*. *Foundations and Trends in Machine Learning*, 14(3), 1–175. <https://doi.org/10.1561/22000000084>
- Francois-Lavet, V., Henderson, P., Islam, R., Bellemare, M. G., & Pineau, J. (2018). *An introduction to deep reinforcement learning*. *Foundations and Trends in Machine Learning*, 11(3-4), 219–354. <https://doi.org/10.1561/22000000071>
- Ge, Z., Song, Z., Gao, F., & Huang, B. (2021). *Semi-supervised learning for process modeling and control*. *Annual Reviews in Control*, 51, 267–282. <https://doi.org/10.1016/j.arcontrol.2020.12.003>
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer.
- Huang, X., Wang, S., & Li, Q. (2023). *Self-supervised learning for medical image analysis: A survey*. *Medical Image Analysis*, 88, 102850. <https://doi.org/10.1016/j.media.2023.102850>
- Jurafsky, D., & Martin, J. H. (2023). *Speech and language processing* (3rd ed.). Prentice Hall.
- Kaelbling, L. P., Littman, M. L., & Moore, A. W. (1996). Reinforcement learning: A survey. *Journal of Artificial Intelligence Research*, 4, 237–285. <https://doi.org/10.1613/jair.301>
- Kotsiantis, S. B. (2007). *Supervised machine learning: A review of classification techniques*. *Informatica*, 31(3), 249–268.
- Li, Y. (2017). Deep reinforcement learning: An overview. *arXiv preprint arXiv:1701.07274*. <https://arxiv.org/abs/1701.07274>

- M. I. Jordan, & Mitchell, T. M. (2015). Machine learning: Trends, perspectives, and prospects. *Science*, 349(6245), 255–260. <https://doi.org/10.1126/science.aaa8415>
- Mohri, M., Rostamizadeh, A., & Talwalkar, A. (2018). *Foundations of machine learning* (2nd ed.). MIT Press.
- Peña Argüeso, J. L. (2023). *Clustering techniques in urban rail transport*. Universidad de Sevilla.
- Perera, A. T. D. (2021). *Reinforcement learning for building energy management: Opportunities and challenges*. *Applied Energy*, 300, 117342. <https://doi.org/10.1016/j.apenergy.2021.117342>
- Rani, S. (2023). *Self-supervised learning for computer vision: Concepts and trends*. *Pattern Recognition Letters*, 165, 108–118. <https://doi.org/10.1016/j.patrec.2022.12.004>
- Sutton, R. S., & Barto, A. G. (2018). *Reinforcement learning: An introduction* (2nd ed.). MIT Press.
- Usama, M., Qadir, J., & others. (2017). *Unsupervised machine learning for networking: Techniques, applications and research challenges*. *IEEE Access*, 5, 19093–19115. <https://doi.org/10.1109/ACCESS.2017.2757955>
- Vafaei Sadr, A., Pour, N., & others. (2023). Dimensionality reduction techniques for unsupervised learning: A review. *Knowledge-Based Systems*, 272, 110606. <https://doi.org/10.1016/j.knosys.2023.110606>
- van Engelen, J. E., & Hoos, H. H. (2020). *A survey on semi-supervised learning*. *Machine Learning*, 109, 373–440. <https://doi.org/10.1007/s10994-019-05855-6>
- Zaharakis, I. D., & Pintelas, P. E. (2007). *Machine learning techniques for classification*. In S. B. Kotsiantis (Ed.), *Informatica*, 31(3), 249–268.


CIBERGRAFÍA

- IBM. (2023). *What is semi-supervised learning?*. IBM Knowledge Center. <https://www.ibm.com>
- IBM. (2025). *What is self-supervised learning?*. IBM Research Blog. <https://research.ibm.com>
- Wired. (2021). *Facebook's SEER AI learns to see by watching everything*. <https://www.wired.com>
- V7 Labs. (2022). *Applications of self-supervised learning in video analysis*. <https://www.v7labs.com>

ANEXOS

Diagrama de flujo del Proceso de búsqueda y extracción de la bibliografía:

Figura 1: Proceso de búsqueda y extracción de la bibliografía



Fuente: Elaboración Propia

Tabla 4: Referencias Extraídas Según Repositorio

Repositorio / Fuente	Referencias extraídas
Google Scholar / Scopus (artículos indexados en revistas científicas)	- Ahfock (2023). Journal of Biomedical Informatics. - Eckardt et al. (2022). Computational Linguistics Journal. - Ericsson et al. (2021). Foundations and Trends in ML. - Francois-Lavet et al. (2018). Foundations and Trends in ML. - Ge et al. (2021). Annual Reviews in Control. - Huang et al. (2023). Medical Image Analysis. - Kaelbling et al. (1996). Journal of Artificial Intelligence Research. - Kotsiantis (2007). Informatica. - Jordan & Mitchell (2015). Science. - Perera (2021). Applied Energy. - Rani (2023). Pattern Recognition Letters. - Usama et al. (2017). IEEE Access. - Vafaei Sadr et al. (2023). Knowledge-Based Systems. - van Engelen & Hoos (2020). Machine Learning. - Zaharakis & Pintelas (2007). Informatica.
SpringerLink Editoriales académicas	- Bishop (2006). <i>Pattern recognition and machine learning</i>. Springer. - Cord & Delany (2008). En <i>Machine learning techniques for multimedia</i>. Springer. - Hastie, Tibshirani & Friedman (2009). <i>The elements of statistical learning</i>. Springer.
MIT Press	- Chapelle, Schölkopf & Zien (2006). <i>Semi-supervised learning</i>. MIT Press. - Mohri, Rostamizadeh & Talwalkar (2018). <i>Foundations of machine learning</i> (2nd ed.). MIT Press. - Sutton & Barto (2018). <i>Reinforcement learning: An introduction</i> (2nd ed.). MIT Press.
ArXiv (repositorio de preprints)	- Li (2017). <i>Deep reinforcement learning: An overview</i>. arXiv preprint arXiv:1701.07274.
Editoriales / Universidades	- Jurafsky & Martin (2023). <i>Speech and language processing</i>. Prentice Hall. - Peña Argüeso (2023). <i>Clustering techniques in urban rail transport</i>. Universidad de Sevilla.
Portales tecnológicos y blogs especializados	- Belcic & Stryker (2024). <i>Supervised learning: Concepts and applications</i>. TechTarget. - IBM (2023). What is semi-supervised learning?. IBM Knowledge Center. - IBM (2025). What is self-supervised learning?. IBM Research Blog. - Wired (2021). Facebook's SEER AI learns to see by watching everything. - V7 Labs (2022). Applications of self-supervised learning in video analysis.

Fuente: Elaboración Propia